



Pytorch框架与 经典卷积神经网络与实战(一)

从全连接到卷积神经网络、LeNet、AlexNet

By~ yixuan

<https://github.com/yhe8479-ship-it>

01

背景基础：从全连接到卷积神经网络

- 全连接神经网络的结构与问题
- 图像在计算机中的本质
- 为什么需要CNN?

02

核心原理：卷积神经网络（CNN）是怎么工作的

- 卷积运算与核的概念
- 填充、步幅、输出尺寸计算
- 多通道卷积（立体视角）
- 池化层（最大池化 / 平均池化）
- 感受野与CNN整体结构

03

经典模型（一）： LeNet-5 原理与结构

- 诞生背景与设计目标
- 网络结构及参数详解
- 平均池化 + sigmoid

04


经典模型（二）： AlexNet 原理与创新

- 网络结构与参数详解
- ReLU、Dropout、最大池化
- 数据增强 & LRN 正则化
- 与LeNet的关键对比


01

背景基础：从全连接 到卷积神经网络


全连接神经网络 的整体结构



全连接神经网络 的整体结构



前向传播具体计算过程



前向传播计算公式：

$$\begin{aligned}a_{11} &= \text{sigmoid}(x_1 w_{11} + b_1) \\a_{21} &= \text{relu}(a_{11} w_{21} + b_2) \\y &= a_{21}\end{aligned}$$

具体计算过程：

初始化的值为 $w_{11} = 0.5$, $w_{21} = 1$, $b_1 = 0.5$, $b_2 = 1$ 。初始化的值为 $w_{11} = 0.5$, $w_{21} = 1$, $b_1 = 0.5$, $b_2 = 1$, $x_1 = 1$, $label = 2$ 。


$$a_{11} = \text{sigmoid}(1 \times 0.5 + 0.5)$$

• 定义损失函数 •

回归Regression -> 均方差损失函数


分类Classification -> 交叉熵损失函数

反向传播---梯度 下降法参数更新



梯度下降法参数更新的计算公式就如下所示：

$$w = w - a \frac{\partial J(w)}{\partial w}$$



反向传播---梯度下降法参数更新

假设有两个参数，随机初始值为 w^0, b^0 。要计算损失关于 w, b 的偏导数，计算在 $w = w^0$ 的位置， $b = b^0$ 的位置，要计算 L 关于 w 的偏导数，计算 L 关于 b 的偏导数：

$$\begin{aligned} \frac{\partial L}{\partial b} \Big|_{w=w^0, b=b^0} \\ \frac{\partial L}{\partial w} \Big|_{w=w^0, b=b^0} \end{aligned} \quad (1.9)$$

计算完后更新 w 跟 b ，把 w^0 减掉学习率乘上微分的结果得到 w^1 ，把 b^0 减掉学习率乘

上微分的结果得到 b^1 。

$$\begin{aligned} w^1 &\leftarrow w^0 - \eta \frac{\partial L}{\partial w} \Big|_{w=w^0, b=b^0} \\ b^1 &\leftarrow b^0 - \eta \frac{\partial L}{\partial b} \Big|_{w=w^0, b=b^0} \end{aligned} \quad (1.10)$$

图像在计算机中的本质




```
0 2 15 0 0 11 10 0 0 0 9 9 0 0 0
0 0 0 4 00 157 236 255 255 177 95 41 32 0 0 29
0 10 10 119 238 255 244 243 250 249 255 222 103 10 0
0 14 170 255 253 244 254 255 253 245 255 249 253 251 124 1
2 90 255 220 255 251 254 211 141 116 222 215 251 230 255 49
13 217 243 255 155 33 226 52 2 0 10 13 232 255 255 36
16 229 252 254 49 12 0 0 7 7 0 70 237 252 235 62
6 141 245 255 212 25 11 9 3 0 115 236 243 255 137 0
0 87 252 250 248 215 60 0 1 121 252 255 248 144 6 0
0 13 113 255 255 245 255 182 181 248 252 242 208 36 0 19
1 0 5 117 251 255 241 255 247 205 241 162 17 0 7 0
0 0 0 4 58 251 255 246 254 253 255 120 11 0 1 0
0 0 4 97 255 255 255 248 252 255 244 255 182 10 0 4
0 22 209 252 246 251 241 100 24 113 255 245 255 194 9 0
0 111 255 242 255 158 24 0 0 6 39 255 232 230 56 0
0 218 251 250 137 7 11 0 0 0 2 62 255 250 125 3
0 173 255 255 101 9 20 0 13 3 13 182 251 245 61 0
0 107 251 241 255 230 88 55 19 118 217 248 253 255 52 4
0 18 146 250 255 247 255 255 255 249 255 240 255 129 0 5
0 0 29 113 215 255 250 248 255 255 248 248 118 14 12 0
0 0 6 1 0 52 153 233 255 252 147 37 0 0 4 1
0 0 5 5 0 0 0 0 14 1 0 0 6 0 0
```



全连接神经网络 存在问题


全连接神经网络



图像信息丢失

VS

CNN卷积神经网络



图像信息保留 直接作为输入

02

核心原理：卷积神经网络 (CNN) 是怎么工作的

卷积运算

输入

0	1	2
3	4	5
6	7	8

核

0	1
2	3

*

=

输出

19	25
37	43

卷积运算

0	1	2
3	4	5
6	7	8

*

0	1
2	3

=

19	

0	1	2
3	4	5
6	7	8

*

0	1
2	3

=

19	25

0	1	2
3	4	5
6	7	8

*

0	1
2	3

=

19	25
37	

0	1	2
3	4	5
6	7	8

*

0	1
2	3

=

19	25
37	43

加入偏置的卷积 运算

输入

0	1	2
3	4	5
6	7	8

*

核

0	1
2	3

+

偏置

2

=

输出

21	27
39	45

填充

0	0	0	0	0
0	0	1	2	0
0	3	4	5	0
0	6	7	8	0
0	0	0	0	0

*

0	1
2	3

=

0	3	8	4
9	19	25	10
21	37	43	16
6	7	8	0

步幅

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	57

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	57
20	

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	57
20	32

经过卷积运算后的 特征图大小

计算公式：（重要）

$$OH = \frac{H + 2P - FH}{S} + 1 \leftarrow$$

$$OW = \frac{W + 2P - FW}{S} + 1 \leftarrow$$

0	0	0	0	0
0	0	1	2	0
0	3	4	5	0
0	6	7	8	0
0	0	0	0	0

*

0	1
2	3

=

0	3	8	4
9	19	25	10
21	37	43	16
6	7	8	0



$$OH = \frac{3 + 2 * 1 - 2}{1} + 1 = 4 \leftarrow$$

$$OW = \frac{3 + 2 * 1 - 2}{1} + 1 = 4 \leftarrow$$

多通道数据卷积

运算

4*4*3

		4	2	1	2
	3	0	6	5	4
1	2	3	0	3	2
0	1	2	3	0	5
3	0	1	2	1	
2	3	0	1		

*

3*3*3

		4	0	2
	0	1	3	0
2	0	1	2	2
0	1	2	0	
1	0	2		

=

63	

三次计算相加

		4	2	1	2
	3	0	6	5	4
1	2	3	0	3	2
0	1	2	3	0	5
3	0	1	2	1	
2	3	0	1		

*

		4	0	2
	0	1	3	0
2	0	1	2	2
0	1	2	0	
1	0	2		

=

63	55

		4	2	1	2
	3	0	6	5	4
1	2	3	0	3	2
0	1	2	3	0	5
3	0	1	2	1	
2	3	0	1		

*

		4	0	2
	0	1	3	0
2	0	1	2	2
0	1	2	0	
1	0	2		

=

63	55
18	

		4	2	1	2
	3	0	6	5	4
1	2	3	0	3	2
0	1	2	3	0	5
3	0	1	2	1	
2	3	0	1		


*

		4	0	2
	0	1	3	0
2	0	1	2	2
0	1	2	0	
1	0	2		

=

63	55
18	51


利用立体图来表示卷积运算





· 利用立体图来表示卷积运算 ·

图像的通道数3，所以这里通道数C也是3


图像的RGB通道数3



*




⋮



FN个

卷积核个数FN，1个卷积核得到1个特征图（尽管是RGB三通道），FN个卷积核得到FN个特征图


通道数FN




通道数 = 当前这一层输入数据的深度（灰度1 / RGB3）

通道数 = 当前这一层输入数据的深度 = 上一层输出特征图的数量 = 上一层卷积核的个数

利用立体图来表示卷积运算



• 利用立体图来表示卷积运算 •



池化——最大池化

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



2	

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



2	5

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



2	5
4	

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



2	5
4	2

池化——平均池化

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



1	

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



1	3

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



1	3
2	

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



1	3
2	1

经过池化层后的 特征图大小

感受野的尺寸

计算公式:

$$OH = \frac{H + 2P - FH}{S} + 1 \leftarrow$$
$$OW = \frac{W + 2P - FW}{S} + 1 \leftarrow$$

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



1	

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



1	3

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2



1	3
2	

1	2	3	3
0	1	1	5
3	0	1	0
1	4	1	2




1	3
2	1



$$OH = \frac{4 + 2 * 0 - 2}{2} + 1 = 2 \leftarrow$$

$$OW = \frac{4 + 2 * 0 - 2}{2} + 1 = 2 \leftarrow$$

卷积神经网络整体结构





03

经典模型（一）： LeNet-5 原理与结构

LeNet-5网络诞生背景


→ 五层：含参数的（池化不算）

发明者：贝尔实验室的研究员Yann LeCun

提出时间：1989年提出

研究目的：手写数字识别

第一次用CNN



LeNet-5 网络结构

当时最大池化还没问世，最大池化效果好于平均池化

LeNet (LeNet-5) 由两个部分组成：

特征提取部分：由两个卷积层和两个平均池化层组成；回归Regression

全连接层：由三个全连接层组成。分类Classification

模型单元结构：

一个卷积层、一个sigmoid激活函数，一个池化层


数据的传输：

卷积层输入为4维的数据 (B,C,W,H) 批次, 通道, 输入宽, 输入高

卷积层输出为4维的数据 (B,FN,OW,OH) 批次, 卷积核个数, 输出宽, 输出高


全连接层的输入为2维数据 (B,L)

全连接层的输出为2维数据 (B,FL)



卷积 -> 通道数变大
池化 -> 特征图变小

LeNet-5网络参数详解



展平后得到400个数据
(作为全连接输入的400个x)

通道1, 灰度图

输入(1×28×28)

5×5卷积(6), 填充2 步幅1

2×2平均池化层, 步幅2 填充0

5×5卷积(16), 填充0


2×2平均池化层, 步幅2

全连接层(120)

全连接层(84)

全连接层(10)

10分类




$$OH = \frac{H + 2P - FH}{S} + 1 \leftarrow$$
$$OW = \frac{W + 2P - FW}{S} + 1 \leftarrow$$

• LeNet-5总结 •

LeNet-5总结

- 1、卷积神经网络（CNN）是一类使用卷积层的网络。
- 2、在卷积神经网络中，组合使用卷积层、非线性激活函数sigmoid和全连接层。
- 3、为了构造高性能的卷积神经网络，我们通常对卷积层进行排列，逐渐降低其表示的空间分辨率，同时增加通道数。
- 4、在传统的卷积神经网络中，卷积块编码得到的表征在输出之前需由一个或多个全连接层进行处理。
- 5、LeNet是最早发布的卷积神经网络之一，它的问世有开创意义





04

经典模型（二）： AlexNet 原理与创新

AlexNet 网络结构

AlexNet和LeNet的设计理念非常相似，但也存在显著差异。


1. AlexNet比相对较小的LeNet5要深得多。

AlexNet由八层组成：五个卷积层、两个全连接隐藏层和一个全连接输出层。

3. 用最大池化而不是平均池化。

4. AlexNet使用ReLU而不是sigmoid作为其激活函数。

卷积层 激活函数 池化层



AlexNet

网络参数详解

第1层输入层： Input为 $227 \times 227 \times 3$

第2层卷积层： Input为 $227 \times 227 \times 3$ ，卷积核为 $11 \times 11 \times 3 \times 96$ ； stride=4, output为 $55 \times 55 \times 96$

第3层最大池化层： Input为 $55 \times 55 \times 96$ ，池化感受野为 3×3 ， stride=2, output为 $27 \times 27 \times 96$

第4层卷积层： Input为 $27 \times 27 \times 96$ ，卷积核为 $5 \times 5 \times 96 \times 256$ ； stride=1, padding=2, output为 $27 \times 27 \times 256$

第5层最大池化层： Input为 $27 \times 27 \times 256$ ，池化感受野为 3×3 ， stride=2, output为 $13 \times 13 \times 256$

第6层卷积层： Input为 $13 \times 13 \times 256$ ，卷积核为 $3 \times 3 \times 256 \times 384$ ， stride=1, padding=1, output 为 $13 \times 13 \times 384$


第7层卷积层： Input为 $13 \times 13 \times 384$ ，卷积核为 $3 \times 3 \times 384 \times 384$ ， stride=1, padding=1, output 为 $13 \times 13 \times 384$ 。

第8层卷积层： Input $13 \times 13 \times 384$ ，卷积核为 $3 \times 3 \times 384 \times 256$ ， stride=1, padding=1, output 为 $13 \times 13 \times 256$


第9层最大池化层： Input为 $13 \times 13 \times 256$ ，池化感受野为 3×3 ， stride=2, output 为 $6 \times 6 \times 256$ ， Flatten操作，通过展平得到9216个数据后与之后的全连接层相连。

第10~12层全连接层：第10~12层神经元个数分别为4096，4096，1000。其中前两层在使用relu后还使用了Dropout对神经元随机失活，最后一层全连接层用softmax输出1000个分类（这里要说的是， softmax输出1000个分类原因是当时该网络设计是为了参加ImageNet这个比赛，该比赛最后是对1000个物体进行分类）。

特征提取



Dropout



正常流程:

先把 x 通过网络前向传播, 然后把误差反向传播以决定如何更新参数让网络进行学习。

Dropout流程:

(1) 首先**随机** (临时) 删掉网络中一半的**隐藏 神经元**, 输入输出神经元保持不变 (图中虚线为部分临时被删除的神经元)


(2) 然后把输入 x 通过修改后的网络前向传播, 然后把得到的损失结果通过修改的网络反向传播。一小批训练样本执行完这个过程后, 在**没有被删除的神经元上按照随机梯度下降法更新对应的参数** (w , b) 。

(3) 然后继续重复这一过程。**有些参数在本轮中不更新, 下轮中更新。**


- (1) 快
- (2) 防止过拟合

图像增强

水平翻转




随机裁剪



更健壮，防止过拟合

PCA



LRN正则化

局部归一化作用：

对局部的值进行归一化操作，使其中比较大的值变得相对更大，**增强了局部的对比度**，在 AlexNet 中有 1.2 个百分点左右的提升。


$$b_{x,y}^i = a_{x,y}^i / \left(k + \alpha \sum_{j=\max(0, i-n/2)}^{\min(N-1, i+n/2)} (a_{x,y}^j)^2 \right)^{\beta}$$

局部归一化流程：



1、手动设置的超参 (k , α , β , n)

n 表示范围数： $n=2$ 左一个右一个； $n=4$ 左两个右两个

2、对每个值利用公式计算局部归一化后的值。




LRN正则化



$$b_{x,y}^i = a_{x,y}^i / \left(k + \alpha \sum_{j=\max(0, i-n/2)}^{\min(N-1, i+n/2)} (a_{x,y}^j)^2 \right)^\beta$$

计算过程，以第二个通道的第一个值归一化为例：

- 1、首先设置超参数 $(k, \alpha, \beta, n) = (0, 1, 1, 2)$
- 2、计算需要归一化的值和周边值的平方和， $1^2 + 1^2 + 2^2 = 6$
- 3、需要归一化的值除以上述平方和； $1/6 = 0.17$ ，即可以得出归一化后的值。



AlexNet总结

AlexNet总结

1、AlexNet和LeNet设计上有一脉相承之处，也有区别。为了适应ImageNet中大尺寸图像，其使用了大尺寸的卷积核，从 11×11 到 5×5 到 3×3 ，AlexNet的卷积层和全连接层也带来更多的参数6000万，这一全新设计的CNN结构在图像分类领域取大幅超越传统机器学习，自此之后CNN在图像分类领域被广泛应用。


2、使用了Relu替换了传统的sigmoid或tanh作为激活函数，大大加快了收敛，减少了模型训练耗时。

3、使用了Dropout，提高了模型的准确度，减少过拟合，这一方式再后来也被广泛采用。

4、在CNN中使用重叠的最大池化。此前CNN中普遍使用平均池化，AlexNet全部使用最大池化，避免平均池化的模糊化效果。并且AlexNet中提出让步长比池化核的尺寸小，这样池化层的输出之间会有重叠和覆盖，提升了特征的丰富性。




5、使用数据了3种数据扩增技术，大幅增加了训练数据，增加模型鲁棒性，减少过拟合。

6、使用了LRN正则化、多GPU并行训练的模式(不过之后并没有被广泛应用)






A decorative frame consisting of a thin black rectangle with small squares at each of the four corners.

LeNet与AlexNet 实战与结果展示



测试样本总数: 10000
预测正确样本数: 8587
测试集准确率为: 0.8587



测试样本总数: 10000
预测正确样本数: 8993
测试集准确率为: 0.8993

Pred: Ankle boot
True: Ankle boot




Pred: Pullover
True: Pullover



Pred: Trouser
True: Trouser



Pred: Trouser
True: Trouser



Pred: Shirt
True: Shirt



Pred: Trouser
True: Trouser



Pred: Coat
True: Coat



Pred: Shirt
True: Shirt



Pred: Sandal
True: Sandal



Pred: Sneaker
True: Sneaker





THANK YOU~~